GPT SoVITS Windows VoiceLab
操作說明書

部署包 v1.6 ｜ Windows 10／11 ｜ NVIDIA GPU ｜ 繁體中文

本手冊帶您完成本機部署、參考錄音準備、免訓練語音克隆、14 頁英文報告配音與影片合成。已能正常啟動介面的電腦，可直接從第 4 節開始，不必重新安裝。

本次使用硬體為 RTX 5090，約 32 GB 顯示記憶體。GitHub 程式基準為 6f227fd；主分支已核對 66 個檔案，包括 8 個 CMD、10 個腳本與 14 張 4K 圖片。

選擇要執行的入口

入口	執行時機與功能
01_Install.cmd	新電腦首次安裝；建立環境、下載程式與模型並檢查。
02_Check_GPU_Models.cmd	安裝後或排錯時，檢查套件、CUDA 與必要模型檔。
03_Start_WebUI.cmd	平常使用；開啟操作介面與語音推理工具。
04_Start_API.cmd	批次旁白前啟動；提供本機 9880 連接埠。
05_Prepare_Reference.cmd	將長錄音擷取成預設 7 秒參考 WAV。
06_Batch_14_Slides.cmd	依配對表與逐頁講稿生成 14 頁旁白。
07_Make_Presentation_Video.cmd	將 14 張圖片與 14 個 WAV 合成 MP4。
08_Repair_WebUI.cmd	介面套件異常時修復；正常時不用執行。

閱讀順序

首次部署看第 2–3 節；第一次語音克隆看第 4–5 節；製作報告影片看第 6–8 節；微調、備份與排錯看第 9–10 節。

專案：https://github.com/wangsungwen/GPTSoVITS-Windows-VoiceLab

2　下載與首次安裝

準備與解壓縮

1. 開啟 GitHub 專案，選 Code → Download ZIP。若要完全重現本手冊版本，可下載提交 6f227fd 的原始碼封存檔。

2. 完整解壓後，將包含 01_Install.cmd 與 scripts 的那一層資料夾命名為 D:\VoiceLab。不要形成 D:\VoiceLab\GPTSoVITS-Windows-VoiceLab-main\01_Install.cmd 的額外層級。

3. 路徑使用英文且不含空白。安裝 NVIDIA 驅動後重新開機；安裝期間保持網路連線，建議預留 50 GB 作業空間。此容量是操作餘裕，不是官方最低需求。

執行安裝與檢查

1. 雙擊 01_Install.cmd。預設使用 CU128 與 Hugging Face 來源；會下載 Miniforge、Python 3.10、PyTorch、模型與所需套件。

2. 等待 INSTALL CHECKS PASSED。關閉視窗前檢查是否有錯誤；下載大型檔案時可能暫時沒有新訊息，不要因此重複啟動安裝。

3. 執行 02_Check_GPU_Models.cmd。檢查 cuda_available 為 true、errors 為空陣列，並查看 logs\doctor.json。

4. 執行 03_Start_WebUI.cmd。能看到網頁後，再依第 4 節實際生成一小段語音。

此版本固定的主要設定

項目	設定
官方來源快照	b4570b876f5c086819ba84e3215472733c6a7b70
語音模型版本	v2Pro
PyTorch 與 TorchAudio	2.7.1；預設 CUDA 12.8 配對
Gradio 與 FastAPI	4.44.1 與 0.115.6
Starlette 與 Pydantic	0.41.3 與 2.10.6
Python 套件隔離	停用 user site，清空繼承的 PYTHONPATH

nvidia-smi 顯示的 CUDA 版本是驅動可支援的能力，不等於目前 Python 環境使用的 PyTorch CUDA 版本。以 doctor 的實際 CUDA 運算結果為準。

目前已收到 Windows 安裝、WebUI 修復通過及介面可使用的回報；這不代表微調訓練與完整影片流程均已完成實機測試。

3　資料夾與更新方式

以下路徑均以 D:\VoiceLab 為根目錄。GitHub 以 .gitkeep 保留空資料夾；這些標記檔不代表環境或模型已經安裝。

相對位置	用途與包內狀態
.runtime\miniforge	隔離的 Conda 執行環境；安裝時建立。
.runtime\gptsovits	GPT-SoVITS 的 Python 環境；安裝時建立。
GPT-SoVITS\	安裝時取得的官方程式。包內僅預建資料目錄。
GPT-SoVITS\GPT_SoVITS\pretrained_models\	官方預訓練模型；由安裝流程下載。
GPT-SoVITS\dataset\	選用微調的錄音、切片與標註資料。
scripts\	PowerShell 及 Python 操作工具。
texts\	slide_01.txt 至 slide_14.txt；原始內容為待填模板。
slides.csv	每頁 id、講稿路徑與目標語言的配對表。
reference\	reference.wav 與同段錄音的 reference.txt。包內未含私人錄音。
slides\	14 張 3840×2160 PNG，含更新後第 11 頁。
output_audio\	逐頁 WAV 與 generation_report.json。
logs\ 與 downloads\	檢查日誌、套件清單、下載快取。
tts_local.yaml	安裝後建立的本機 API 設定；已有檔案時保留。
ES0003_Presentation.mp4	影片合成後出現在根目錄。

更新已能運作的電腦

先停止 WebUI、推理子程序與 API，再備份目前 D:\VoiceLab。只覆蓋新版 8 個 CMD、scripts 資料夾與說明文件。保留 .runtime、GPT-SoVITS、tts_local.yaml、slides.csv、texts、reference、slides 與輸出檔，避免模板覆蓋個人內容。

下載的原始碼包不包含您電腦上的實際環境、模型、私人錄音或已生成結果。要將同一套成果移往另一台電腦，需另外備份這些檔案；環境通常建議在新電腦重新安裝。

4　啟動介面與第一次語音克隆

啟動主介面

1. 雙擊 03_Start_WebUI.cmd，等待終端機顯示本機網址。主介面通常為 http://127.0.0.1:9874；以實際顯示為準。

2. 保持啟動視窗開啟。在瀏覽器進入 1-GPT-SoVITS-TTS，再選 1C-推理。不同語系的標籤可能略有差異。

3. 選擇 v2Pro 對應的 GPT 與 SoVITS 模型，GPU 使用 0，再按介面提供的開啟 TTS 推理 WebUI 按鈕。

4. 依終端機顯示網址開啟推理頁，通常為 http://127.0.0.1:9872。

欄位	第一次測試設定
GPT 權重	GPT_SoVITS/pretrained_models/s1v3.ckpt
SoVITS 權重	GPT_SoVITS/pretrained_models/v2Pro/s2Gv2Pro.pth
參考音訊	同一位說話者，3–10 秒；建議完整的 5–8 秒句子。
參考文字與語言	填入錄音真正說出的逐字稿，語言與錄音一致。
目標文字與語言	先用短句；英文報告選英文。

先用一句話測試

```
Hello everyone. My name is Sung-Wen Wang.
Today, I will present our research.
```

按下合成後，等待音訊播放器出現。逐句試聽人名、縮寫、尾音與停頓；確認可以播放及匯出 WAV，再增加講稿長度。看到網頁不等於模型已成功載入，產出可播放的語音才是第一次推理的成功條件。

停止與重新啟動

停止時在啟動視窗按 Ctrl+C；若 Windows 詢問是否終止批次工作，依提示確認。另開的推理視窗也要停止。若要改用批次 API，先釋放原先載入的語音模型，避免同時占用顯示記憶體。

免訓練語音克隆利用參考音訊提供音色條件，不會自動產生一組屬於您的微調權重。需要個人權重時再進行第 9 節的訓練。

5　準備參考錄音與逐字稿

錄音內容與品質

使用本人或已獲授權的單人錄音。選擇安靜房間，固定麥克風距離，避免背景音樂、多人聲、明顯迴音與削波。音量以清晰且不失真為原則，不必刻意大聲。

英文報告建議錄一段自然英文句子。中文參考音訊可以嘗試跨語言生成英文，但口音、術語與音色仍需逐段試聽。不要將新講稿誤填成參考逐字稿。

使用 05 擷取 7 秒 WAV

1. 先聽原始錄音，找出可自然開始與結束的片段。雙擊 05_Prepare_Reference.cmd。

2. 在 Input recording path 輸入原始錄音完整路徑，例如 D:\Recordings\my_voice.m4a。此提示不要在路徑外加雙引號。

3. 在 Start time in seconds 輸入起始秒數，例如 12.5。工具會擷取後續 7 秒。

4. 完成後試聽 D:\VoiceLab\reference\reference.wav，確認沒有切斷開頭或尾音。若 7 秒不適合，可自行準備自然完整、長度 3–10 秒的 WAV。

5. 用記事本開啟 reference\reference.txt，刪除 [REPLACE ...] 待填文字，輸入這一段錄音的精確逐字稿，以 UTF-8 儲存。

檢查項目	合格條件
長度	3–10 秒；05 的預設為 7 秒。
05 輸出規格	單聲道、32 kHz、16-bit PCM WAV。
內容對齊	逐字稿與 reference.wav 是完全相同的一段聲音。
語言	WebUI 與批次 prompt-lang 必須符合參考錄音。
已有輸出	05 預設拒絕覆蓋；先備份並更名原檔再執行。

錄音與目標講稿的差別

reference.txt 描述「錄音內已說出的話」；texts\slide_01.txt 描述「接下來希望模型說的話」。兩者用途不同。語音不自然時，先用另一段清楚錄音比較，避免一開始就更改大量推理參數。

6　生成十四頁報告旁白

填入逐頁英文講稿

1. 將核定英文口說稿逐頁放入 texts\slide_01.txt 至 slide_14.txt，以 UTF-8 儲存。這些檔案原先是模板，不能直接當作完整講稿。

2. 開啟 slides.csv。保留 id、text_file、text_lang 欄位，確認每頁路徑正確；英文目標語言為 en。

3. 準備 reference\reference.wav 與 reference.txt。06 的參考語言預設為英文；中文錄音請使用第 7 節指令。

```
id,text_file,text_lang
slide_01,texts/slide_01.txt,en
slide_02,texts/slide_02.txt,en
```

啟動 **API** 後再生成

1. 停止 WebUI 的推理模型，雙擊 04_Start_API.cmd。等待模型載入並看到伺服器啟動訊息；不要在載入中就執行 06。

2. API 綁定 http://127.0.0.1:9880。可開啟 http://127.0.0.1:9880/docs 確認服務回應，但文件頁可開啟仍不等於實際合成成功。

3. 保持 API 視窗開啟，另執行 06_Batch_14_Slides.cmd。工具依序生成 WAV，遇錯會停止並顯示訊息。

4. 完成後檢查 output_audio\slide_01.wav 至 slide_14.wav，逐頁試聽；總音長與每頁耗時可查看 generation_report.json。

生成結果如何判讀

每頁輸出名稱依 CSV 的 id 決定。工具會先驗證講稿非空、沒有 [REPLACE ...]、id 不重複，以及參考 WAV 長度合格。已有同名 WAV 時預設停止，避免覆蓋已核定結果。

若中途失敗，已完成 WAV 會保留；報表記錄該次執行已完成的頁面。以另一次工作重跑時，報表不會自動合併所有歷次結果，因此最終仍須檢查 14 個實際音檔。

大會要求約 10–15 分鐘。先以內容與自然語速生成，再加總實際音長；必要時調整講稿。不要假設每頁有固定秒數，也不要只為時限而盲目加速。

7　預先檢查與單頁重做

以下命令在 Windows PowerShell 執行。先進入部署包根目錄，設定隔離環境；同一視窗執行一次即可。反引號 ` 必須位於該行最後，後面不要加空白。

```
Set-Location D:\VoiceLab
$env:PYTHONNOUSERSITE = '1'
$env:PYTHONPATH = ''
$Conda = 'D:\VoiceLab\.runtime\miniforge\Scripts\conda.exe'
$PyEnv = 'D:\VoiceLab\.runtime\gptsovits'
```

先檢查檔案而不生成語音

```
& $Conda run --no-capture-output -p $PyEnv python `
  .\scripts\batch_tts.py --manifest .\slides.csv `
  --reference .\reference\reference.wav `
  --prompt .\reference\reference.txt --prompt-lang en `
  --out .\output_audio --dry-run
```

看到 Validated 14 jobs 表示本地輸入檢查通過；dry-run 不會連線 API，也不會驗證模型合成。正式生成可直接執行 06，或移除 --dry-run 再執行命令。

只重新生成第十一頁

複製 slides.csv 成 slides_redo.csv，以文字編輯器只保留表頭及 slide_11 那一行。先備份舊 WAV，並確認要替換的講稿已更新。API 必須持續運作。

```
& $Conda run --no-capture-output -p $PyEnv python `
  .\scripts\batch_tts.py --manifest .\slides_redo.csv `
  --reference .\reference\reference.wav `
  --prompt .\reference\reference.txt --prompt-lang en `
  --out .\output_audio --overwrite
```

若要續跑失敗後的頁面，另建 CSV 只保留未完成頁面，通常不需 --overwrite。不要直接把包含所有既有 WAV 的完整 CSV 重跑，否則預設會因同名輸出而停止。

使用中文參考錄音

將上述命令的 --prompt-lang en 改成 --prompt-lang zh，並確認 reference.txt 是中文錄音的實際文字。CSV 的 text_lang 仍可保持 en，代表目標輸出英文。

工具支援 --speed 0.5 至 2，預設為 1；改變速度仍應試聽。使用 --overwrite 僅代表允許取代 CSV 所選頁面的同名 WAV，不會自動決定哪些頁面需要重做。

8　合成影片與提交前檢查

確認每頁圖片與音檔配對

頁碼	圖片位置	旁白位置
01	slides\ES0003_Slide_01.png	output_audio\slide_01.wav
02	slides\ES0003_Slide_02.png	output_audio\slide_02.wav
11	slides\ES0003_Slide_11.png	output_audio\slide_11.wav
14	slides\ES0003_Slide_14.png	output_audio\slide_14.wav

03–10、12–13 頁依相同命名規則。slides 資料夾放逐頁 PNG，不放 PPTX 或 PDF。更新簡報第 11 頁後，替換同名 PNG；若旁白也有改動，先依第 7 節重做對應 WAV。

執行影片合成

1. 確認全部 14 張圖片與 14 個 WAV 均存在且可以開啟。若有一頁缺檔，工具會停止並指出頁碼。

2. 雙擊 07_Make_Presentation_Video.cmd。這個步驟使用 FFmpeg，不必先啟動 TTS API。等待全部頁面編碼及串接完成。

3. 開啟 D:\VoiceLab\ES0003_Presentation.mp4，完整播放一次。影片不會自動寄信或上傳大會。

輸出項目	此版本設定
解析度與影格率	1920×1080，30 FPS；4K 來源縮為 1080p。
影像格式	H.264，yuv420p；等比縮放，必要時補邊。
聲音格式	AAC，192 kbps，48 kHz，雙聲道。
頁面停頓	每頁音訊後補 0.5 秒；14 頁合計約 7 秒。
總時間	14 個音檔總時長加約 7 秒；以最終播放器為準。

重新合成與交付

已有同名 MP4 時，07 預設拒絕覆蓋。先將舊影片備份或更名，再執行 07。只修改圖片不必重新生成所有音檔，但必須重新合成影片。

交付前逐頁確認：畫面順序、文字清晰、圖聲內容相符、人名與術語讀音正確、沒有漏句或重複句，以及總長符合會議要求。保留最終 WAV、PNG 與 MP4，另行依大會信件指示提交。

9　選用微調訓練與成果備份

何時考慮微調

先測試免訓練合成。若更換清楚的參考錄音、校正逐字稿後仍無法得到合適音色，再評估微調。訓練品質取決於語料一致性與標註，不保證增加 epochs 就一定改善。

1. 將原始錄音備份到獨立位置，再放入 GPT-SoVITS\dataset\raw。以同一位說話者的乾淨、多樣句子為主。

2. 在主 WebUI 使用音訊切片工具，取得自然句子的片段；將核對後切片整理於 dataset\wavs。檢查片頭片尾不要切掉發音。

3. 使用 ASR／標註工具建立 .list，逐段人工核對。標註範例：音檔路徑|speaker01|EN|Good afternoon, everyone.

4. 在 GPT-SoVITS 訓練分頁建立實驗名稱，版本選 v2Pro。GPT、SoVITS G／D 與實驗版本須一致，不要混用不同代模型。

5. 依介面順序進行文字處理、HuBERT／SSL 特徵與語意 token 等資料準備，再執行 SoVITS 與 GPT 訓練。先用介面建議的小 batch，若 OOM 則降低 batch 並關閉其他模型程序。

6. 選擇同一實驗對應的 .ckpt 與 .pth，在推理介面測試未用於訓練的新句子。比較咬字、自然度、漏字、重複與音色。

API 改用個人權重

停止 API，備份 tts_local.yaml，再修改其中 t2s_weights_path 與 vits_weights_path 指向個人 GPT 與 SoVITS 權重，並保持 version 與權重一致。重新啟動 04 後先試短句；微調後仍需要參考錄音。

備份範圍

要保留的資料	建議備份內容
個人聲音與講稿	reference、texts、slides.csv、slides。
模型與實驗	GPT-SoVITS 的 GPT_weights_v2Pro、SoVITS_weights_v2Pro、logs、dataset；實際檔名以訓練介面為準。
設定與成果	tts_local.yaml、output_audio、最終 MP4、logs\installed-packages.txt。

關閉相關程序後再備份。完整 D:\VoiceLab 可作為本機留存，但 Conda 環境不保證改路徑或換機仍可直接使用；換機宜重新安裝，再還原個人資料、設定與權重。GitHub 的原始碼庫不會自動備份私人錄音或生成結果。

10　故障排除與驗收

現象	優先處理方式
只看到資料夾沒有模型	預建目錄是正常骨架。新電腦執行 01，再用 02 檢查必要權重。
CUDA unavailable 或 OOM	先看 doctor.json。確認驅動與 CUDA 運算；OOM 時停止其他模型程序，再降低訓練 batch。
torchcodec 找不到版本	使用本包 01 與 scripts；本版固定 Torch／TorchAudio 2.7.1，避免直接重跑未修補的官方安裝腳本。
網頁出現 unhashable type dict	關閉舊 WebUI，執行 08。看到 WEBUI REPAIR CHECKS PASSED 再執行 03。
9874 或 9880 無法開啟	先看終端機是否仍載入模型或已報錯。關閉舊程序，依啟動訊息確認連接埠。
參考 WAV 或講稿檢查失敗	確認 WAV 3–10 秒、逐字稿相符、texts 與 reference.txt 沒有 [REPLACE ...]。
已有同名 WAV 或 MP4	這是覆蓋保護。備份舊檔；單頁旁白依第 7 節選頁並加 --overwrite。
Conda command failed 或 subprocess error	這通常是外層摘要。查看第一個實際錯誤與完整 pip 日誌，保留 stdout／stderr；不要僅憑最後一行判斷根因。

要提供哪些排錯資料

提供出錯入口名稱、操作時間、啟動視窗最後約 30–50 行、logs\doctor.json，以及對應 install 或 webui-repair 日誌。不要只提供「Conda command failed」。一般排錯不需交付私人錄音。

完成工作的判定

安裝完成：INSTALL CHECKS PASSED 且 doctor 無錯誤。介面完成：能開啟主頁與推理頁。語音完成：輸出可播放且已人工試聽。報告完成：14 頁圖片及旁白配對正確，最終 MP4 全片播放正常。這些階段應分別驗收。

程式來源與版本

本手冊依部署包 v1.6 及 GitHub 提交 6f227fdd66e6d3b4c5b11faf18e38fd18d895f14 編寫，日期為 2026-10-24。未提供虛構操作截圖；頁籤名稱與按鈕以固定版本實際介面為準。

部署專案：https://github.com/wangsungwen/GPTSoVITS-Windows-VoiceLab

官方專案：https://github.com/RVC-Boss/GPT-SoVITS